

Grado en Business Data Analytics

Informe final

Reto 09

Curso: 3º 2024-2025

Equipo: [Verde oscuro]

URL del repositorio en Github: https://github.com/xaabizulu/24-25_3_R9_Verde_Oscuro

Autores:

- Aitana Abad
- Jon Ander Jiménez
- Martin Orive
- Guillermo Rubio
- Xabier Zulueta

Índice

Capítulo 1: Introducción	1
Capítulo 2: Identificar la problemática.....	2
2.1 Sobre el cliente.....	2
2.2 Sobre la problemática	2
2.3 Objetivos.....	2
Capítulo 3: Estado del arte.....	3
Capítulo 4: Recogida y almacenamiento de los datos	5
4.1 Fuentes de datos utilizadas.....	5
4.2 Procesamiento de los datos	5
Capítulo 5: Selección de activos (AAPL, GS, MRK)	9
5.1 Descripción y justificación de criterios empleados.....	9
5.2 Análisis y selección de activos.....	9
5.3 Conclusiones	14
5.4 Descripción teórica opciones financieras	15
5.5 Descomposición de series temporales y modelización de la volatilidad	15
Capítulo 6: Estimación de prima de productos financieros	18
6.1 Simulación de Monte Carlo	18
6.2 Implementación y comparación de métodos.....	19
Capítulo 7: Conclusiones	25
Capítulo 8: Implicaciones legales y éticas	26
Capítulo 9: Bibliografía	27

Índice de ilustraciones

Ilustración 1: Distribución de precio de cierre en datos originales. Fuente: Elaboración propia. .	6
Ilustración 2: Comparación métodos de imputación. Fuente: Elaboración propia.....	7
Ilustración 3: Precios Apple previos a corrección por Split. Fuente: Elaboración propia.....	8
Ilustración 4: Precios Apple tras ajuste de Splits. Fuente: Elaboración propia.....	8
Ilustración 5: Rentabilidad vs Volatilidad 10 mejores combinaciones de activos con MRK. Fuente: Elaboración propia.	11
Ilustración 6: Rentabilidad y riesgo de activos y cartera. Fuente: Elaboración propia.	12
Ilustración 7: Frontera eficiente de la cartera. Fuente: Elaboración propia.	13
Ilustración 8: Rentabilidad y riesgo de activos y cartera con pesos optimizados. Fuente: Elaboración propia.	14
Ilustración 9: Gráficos ACF y PACF de el residuo al cuadrado de Apple. Fuente: Elaboración propia.....	17
Ilustración 10: Gráficos ACF y PACF de el residuo al cuadrado de MRK. Fuente: Elaboración propia.....	17
Ilustración 11: Gráfico de las trayectorias de la simulación de Monte Carlo. Fuente: Elaboración propia.....	18
Ilustración 12: Comparación predicciones y valores reales modelos iniciales. Fuente: Elaboración propia.	21
Ilustración 13: Evolución pérdida en 'train' y 'test' con modelo definitivo. Fuente: Elaboración propia.....	23
Ilustración 14: Predicciones y valores reales con modelo definitivo. Fuente: Elaboración propia.	23
Ilustración 15: Comparación predicción de prima mediante 3 métodos con distintos pasos temporales. Fuente: Elaboración propia.	24

Índice de tablas

Tabla 1: Variables de datos originales.	5
Tabla 2: Resultados de test de estacionariedad y homocedasticidad de las tres acciones.	16
Tabla 3: Comparación error y ajuste modelos iniciales.	20
Tabla 4: Mejores 3 modelos según MAE y MSE.....	22
Tabla 5: Métricas e hiper parámetros de modelos probados.....	28
Tabla 6: Resultados ARCH Apple.....	30
Tabla 7: Resultados ARCH MRK.	30
Tabla 8: Resultados GARCH AAPL.	30
Tabla 9: Resultados GARCH MRK.	31

Glosario de siglas

BBVA: *Banco Bilbao Vizcaya Argentaria*

AAPL: *Apple Inc.*

GS: *Goldman Sachs*

MRK: *Merck Sharp & Dohme*

LSTM: *Long Short-Term Memory*, tipo de red neuronal recurrente.

GRU: *Gated Recurrent Unit*, variante de LSTM simplificada, utilizada en redes para procesar secuencias

EDA: Análisis exploratorio de datos

ACF: Función de autocorrelación

PACF: Función de autocorrelación parcial

ARCH: *Autoregressive Conditional Heteroskedasticity*, modelo para capturar homocedasticidad condicional en series temporales.

GARCH: *Generalized Autoregressive Conditional Heteroskedasticity*, extensión de ARCH que captura efectos de volatilidad persistente.

ADF: *Augmented Dickey-Fuller*, prueba para comprobar la estacionariedad de series temporales.

KPSS: *Kwiatkowski-Phillips-Schmidt-Shin*, prueba de estacionariedad.

RNN: *Recurrent Neural Networks*, redes neuronales recurrentes.

ReLU: *Rectified Linear Unit*, función de activación en redes neuronales.

LeakyReLU: Variante de ReLU que permite un pequeño gradiente negativo.

SGD: *Stochastic Gradient Descent*, método de optimización por descenso de gradiente estocástico.

Adam: *Adaptive Moment Estimation*, algoritmo de optimización.

Sigmoid: Función de activación que transforma valores a un rango entre 0 y 1.

R^2 : Coeficiente de determinación, medida de ajuste de un modelo.

MSE: *Mean Squared Error*, error cuadrático medio.

MAE: *Mean Absolute Error*, error absoluto medio.

ODS: Objetivos de Desarrollo Sostenible.

Glosario de terminología

Monte Carlo: Técnica de simulación estadística utilizada para estimar resultados mediante la generación de múltiples muestras aleatorias.

Black-Scholes: Modelo para calcular el precio de opciones financieras.

Método binomial: Técnica para valorar opciones usando un árbol de decisiones.

Perceptrón: Algoritmo de red neuronal básica.

Ratio de Sharpe: Medida de rendimiento ajustado al riesgo.

Ratio de Sortino: Variante del Ratio de Sharpe que solo considera la volatilidad negativa.

Opción financiera: Contrato que da derecho a comprar o vender un activo a un precio específico.

Opción asiática: Opción cuyo valor se basa en el promedio del precio del activo.

Heterocedasticidad: Variabilidad no constante en los residuos de un modelo.

Test de White: Prueba estadística para detectar heterocedasticidad en un modelo.

Test de Breusch-Pagan: Test para detectar heterocedasticidad relacionando errores y variables.

Test de Goldfeld-Quandt: Test para detectar heterocedasticidad dividiendo datos y comparando varianzas.

Descomposición de Cholesky: Descomposición de matrices que facilita el manejo de matrices simétricas y positivas.

Payoff: Beneficio obtenido de una inversión o un contrato en un momento determinado en el futuro.

Deep Learning: Campo del aprendizaje automático que utiliza redes neuronales profundas.

Early stopping: Técnica para detener el entrenamiento de un modelo cuando el rendimiento deja de mejorar.

Batch normalization: Técnica que normaliza activaciones de redes neuronales para estabilizar el entrenamiento.

Gradient clipping: Técnica para limitar los gradientes y prevenir explosiones de redes neuronales.

Dropout: Método de regularización que desactiva aleatoriamente neuronas durante el entrenamiento.

Learning rate: Tasa que determina el tamaño de los ajustes de los parámetros durante el aprendizaje.

DowJones: Índice bursatil el cual mide el rendimiento de las 30 empresas mas grandes de Estados Unidos.

Machine Learning: Campo de la inteligencia artificial que permite a las máquinas aprender de datos.

Capítulo 1: Introducción

El **crecimiento** acelerado presentado en **tecnologías avanzadas** como la inteligencia artificial o Big Data han **transformado** el **sector bancario** y financiero de manera radical. Estas herramientas han permitido a los bancos mejorar la experiencia del cliente, optimizar sus operaciones y reforzar los sistemas de seguridad entre otras muchas cosas.

En lo que a las opciones financieras corresponde, el Big Data permite a los bancos disponer de mucha **más información**, permitiendo que los profesionales puedan **tomar decisiones más informadas**. El **aprendizaje automático** ofrece **beneficios** significativos en la valoración de opciones financieras, obteniendo mediante su implementación **análisis más precisos y eficientes** que los métodos tradicionales. Gracias a estos algoritmos, se pueden analizar grandes volúmenes de datos históricos y de mercado en tiempo real, identificando patrones complejos y variables que influyen en el precio de las opciones. El siguiente proyecto se ha diseñado con el objetivo de analizar, comprender y **valorar productos** en el mercado financiero mediante modelos de 'machine learning', más concretamente con **redes neuronales recurrentes**, y poder comparar su eficiencia respecto a otros métodos tradicionales.

El **desarrollo** de este proyecto se realizará manteniendo un orden previamente establecido. En primer lugar, en la sección **Identificar la problemática** se reconoce el desafío presentado, en donde se detalla información sobre el cliente, su necesidad, y los objetivos a realizar para poder dar una solución al reto. Posteriormente, se salta al apartado **Estado del arte** para poder contextualizar la problemática e identificar las contribuciones previas, las limitaciones existentes y las áreas de oportunidad para futuras investigaciones. Tras la introducción al tema que suponen estos dos capítulos, se da pie a explicar la recolecta y el tratamiento de los datos mediante el capítulo denominado **Recogida y almacenamiento de los datos**, donde paso a paso se detalla el proceso seguido con los datos que BBVA nos facilitó desde su lectura y análisis exploratorio hasta la imputación de valores ausentes y la preparación de los datos para la posterior modelización.

A continuación, en la parte **Selección de activos (AAPL, GS, MRK)** se realiza un **análisis técnico financiero** donde se describe el proceso y los criterios de **selección** de los **activos** que componen la **cartera** y las conclusiones que se obtienen sobre esta misma, además de la **descripción** teórica de las **opciones financieras**, específicamente, de las asiáticas. Asimismo, en esta sección del informe también se describe el **análisis** fundamentado de las **series temporales** que componen la cartera y la **modelización** y predicción de la **volatilidad** de esta.

Posteriormente, en el sector **Estimación de prima de productos financieros** se explica la implementación de la simulación de **Montecarlo** y las **redes neuronales** en el proyecto, detallando los criterios de evaluación y justificación, el modelo generado y seleccionado para la predicción y las predicciones logradas junto con la comparación final entre las redes neuronales y la fórmula de BBVA respecto a su precisión comparada con Montecarlo. Para finalizar el proyecto, se exponen las **Conclusiones** en un apartado consecuente.

Por último, este informe también consta de un apartado en el que se tratan las repercusiones jurídicas y morales, siendo este el capítulo denominado **Implicaciones legales y éticas**, al igual que de otro denominado **Bibliografía**, que reúne las diferentes fuentes de información utilizadas para poder desarrollar el trabajo.

Capítulo 2: Identificar la problemática

2.1 Sobre el cliente

El cliente de este reto es **BBVA**. Una empresa **referente en el sector financiero** y que cuenta con más de **165 años** de historia. Hasta la creación del actual banco se han realizado varias fusiones entre bancos. Inicialmente, nace el Banco de Bilbao en 1857, tratando de impulsar económicamente la región. En 1988 se firma un acuerdo de fusión entre el Banco de Bilbao y el Banco de Vizcaya, adoptando la marca BBV en 1989.

El gobierno español de Felipe González crea la banca pública Argentaria en 1991, agrupando así los bancos públicos españoles. Finalmente, en el año 2000 se adopta la marca única BBVA fusionando las entidades BBV y la banca Argentaria quedándose presidida por los presidentes anteriores de BBV y Argentaria, Emilio Ybarra y Francisco González respectivamente. El banco BBVA nace con una gran estructura financiera y un tamaño relevante.

A partir de ahí, ha ido creciendo exponencialmente hasta llegar a la actualidad, que cuenta con más de **75,5 millones de clientes** activos y más de **123.000 trabajadores**. En 2023, el Índice estadounidense Dow Jones otorgó a BBVA la mejor puntuación en la categoría de bancos en la región de Europa por cuarto año consecutivo.

2.2 Sobre la problemática

Predecir el valor de los activos es crucial en el mundo financiero, ya que permite a inversores **anticipar movimientos** de mercado y **tomar decisiones informadas**. Una valoración precisa ayuda a maximizar ingresos y realizar una mejor gestión del riesgo.

No obstante, realizar una valoración precisa se convierte en una tarea complicada debido a la **gran volatilidad** que el mercado presenta. Por ello, aunque existen metodologías tradicionales como las ecuaciones de Black-Scholes o el método binomial, hoy en día se demandan técnicas más avanzadas como las **simulaciones de Monte Carlo**. Sin embargo, estas técnicas tienen un alto costo computacional.

Por esta razón, se plantea implementar las **Redes Neuronales Recurrentes**, las cuales son muy útiles para trabajar con datos secuenciales ya que tienen la capacidad de mantener información a través de la memoria interna. Además, la implementación de redes neuronales podría aportar una solución **computacionalmente más eficiente**.

2.3 Objetivos

Este reto propuesto por la empresa BBVA tiene dos objetivos principales. Por una parte, realizar el **análisis financiero** de una cartera formada por tres activos. Estos activos deben ser elegidos con criterios justificados, los cuales mantengan coherencia con la estrategia planteada. Además, se debe **simular la evolución del valor de los activos** que conforman la cartera con el fin de **calcular la prima** para la cartera.

Por otro lado, se tendrá que **optimizar una red neuronal** que prediga la prima simulada con el menor error posible. De esta forma, se podría ver si es posible mejorar las valoraciones de productos financieros sin tener que recurrir a la fórmula cerrada.

Capítulo 3: Estado del arte

A la hora de adentrarse en el mundo financiero, se encuentra un **mercado con cambios constantes** e impredecible ya que está expuesto a muchos factores externos. Por ello, la evaluación de productos y activos es fundamental para la toma de decisiones. Es por ello por lo que durante el último siglo se ha tratado de implementar nuevos cálculos matemáticos, diferentes metodologías y recursos en el sector financiero.

La práctica de negociar opciones financieras se remonta a tiempos antiguos. Los primeros usos documentados de derivados se remontan a la antigua Grecia, ya que Tales de Mileto, aproximadamente en el año 600 a. C., compró la '**opción de compra**' de utilizar las prensas **de aceitunas** [1]. Sin embargo, el primer contrato de opciones que se asemeja a los contratos actuales, el cuál tenía como propósito proteger el precio de los tulipanes, surge **en el siglo XVII**, debido a la alta demanda que estos tenían. Con el tiempo, se desarrollaron **diversos avances** que han dado lugar al mercado de opciones tal como lo conocemos en la actualidad.

Con el objetivo de llevar a cabo la valoración de activos, cuya función se revela como fundamental en el proceso de toma de decisiones, especialmente en un mercado tan dinámico y volátil como el actual, se han desarrollado diferentes métodos a lo largo de los años. Sin embargo, cada vez existen más factores que afectan al precio de estos activos, por lo que se han necesitado soluciones más avanzadas para topa con la solución.

En la década de 1970, Myron Scholes, Robert Merton y Fisher Black llevaron a cabo uno de los avances más importantes en la fijación de precios de opciones financieras, desarrollando lo que se conoce como el **modelo Black-Scholes**. [2] Estos tres economistas norteamericanos desarrollaron una fórmula analítica de fijación de precios para las opciones europeas bajo precios neutrales al riesgo y la suposición de que el precio del activo subyacente sigue un proceso browniano geométrico. [3]

Además del ya mencionado Black-Scholes, existen otros métodos de valoración de opciones como por ejemplo el método Binomial (Cox, Ross y Rubinstein, 1979), el método Binomial con transformación logarítmica (Trigeorgis, 1991) y la **simulación de Monte Carlo** (Boyle, 1977). [4] Lo que les diferencia con Black-Scholes es que no tienen una fórmula cerrada, sino que son aproximaciones numéricas y requieren de una simulación de la evolución del activo subyacente.

En cuanto a las **redes neuronales**, han sido una de las aplicaciones más significativas en el sector financiero a lo largo de los últimos años. En 1936 Alan Turing fue el primero en estudiar el cerebro como una forma de ver el mundo de la computación. Sin embargo, los primeros teóricos que concibieron los fundamentos de la computación neuronal fueron Warren McCulloch, un neurofisiólogo, y Walter Pitts, un matemático, quienes, en 1943, lanzaron una teoría acerca de la forma de trabajar de las neuronas. En 1957 Frank Rosenblatt comenzó el **desarrollo del perceptrón**, creando así la red neuronal más antigua. [5]

También es relevante hablar del **impacto** que está teniendo la **IA en las opciones financieras**. Mediante algoritmos de aprendizaje automático, la IA puede analizar grandes volúmenes de datos financieros, identificando patrones y tendencias que ayuden en la toma de decisiones informadas. Además, la IA también mejora la precisión al reducir errores humanos en cálculos y procesos, lo que a su vez fortalece la integridad de la información financiera y la conformidad con regulaciones. [4]

Gracias al rápido desarrollo de la IA y el aprendizaje automático, se han propuesto **nuevos tipos de redes neuronales artificiales**. Por ejemplo, en 1997, Sepp Hochreiter y Jürgen Schmidhuber propusieron la red neuronal de memoria a largo plazo, llamada **LSTM** ('Long short-term memory'). [6] Este tipo de redes recurrentes trabajan de forma eficiente con datos secuenciales por lo que se consideran una buena aplicación en las opciones financieras. Un caso de uso con este tipo de redes lo implementa Jorge Briones Viqueira en su máster de banca y finanzas. Este, intenta predecir el comportamiento de varias empresas españolas aplicando una red neuronal LSTM, basándose en los datos históricos de las *blue chips* de España. Tras implementar la red y realizar la predicción, se observa como los datos predichos se asemejan bastante a los datos

reales, obteniendo un error muy pequeño. [7] Por ello, se concluye que este tipo de redes son efectivas para este tipo de aplicaciones.

En resumen, ha habido una gran evolución con respecto a los algoritmos de 'machine learning' y modelos matemáticos de hace años. Además, la llegada y mejora constante de las redes neuronales facilita la aplicación de estos métodos en el sector financiero. El uso y aplicaciones de las empresas así lo respalda, concluyendo que este tipo de herramientas han llegado para quedarse.

Capítulo 4: Recogida y almacenamiento de los datos

4.1 Fuentes de datos utilizadas

Para abordar el desafío planteado por BBVA, se emplearon los datos suministrados sobre 26 de las 30 acciones que integran el índice Dow Jones estadounidense. Cada uno de ellos forma un archivo 'csv', los cuales están formados por las siguientes variables expuestas en la Tabla 1:

Tabla 1: Variables de datos originales.

Variable	Descripción
open	Precio de acción en el momento de apertura del mercado.
high	Máximo de precio de acción en el tramo horario.
low	Mínimo de precio de acción en el tramo horario.
last	Último valor de la acción.
close	Valor de la acción al momento de cierre del mercado.
volume	Volumen de compraventas realizadas en el tramo temporal.
date	Fecha y hora del registro.
symbol	Símbolo de la acción.
exchange	Bolsa de la que extraen los valores.

4.2 Procesamiento de los datos

En cuanto al procesamiento de los datos, lo primero de todo se realizó un **análisis exploratorio de datos (EDA)**, en el que se exploraron los datos originales. Para llevar a cabo el análisis exploratorio de datos (EDA) se consolidaron todos los archivos 'csv' que contenían información sobre el índice Dow Jones en un único 'data frame'. Este proceso permitió analizar las características y la calidad de los datos recopilados.

Se realizó un **resumen estadístico** de las variables numéricas que proporcionó una visión general sobre su distribución y características. Al tratarse de un reto en el que se deben de realizar predicciones a futuro mediante diferentes métodos, se buscaron **valores nulos** en varias columnas del conjunto de datos, para poder tratarlos de cara a la modelización. Se encontraron 849.956 valores nulos en la columna 'last', 611.651 valores nulos en la columna 'close' y 847.408 valores nulos en la columna 'volumen'. Es importante tener en cuenta la cantidad significativa de valores nulos en estas columnas, ya que requiere la aplicación estrategias de imputación o eliminación en el siguiente paso del preprocesamiento para así asegurar la calidad del análisis posterior, mediante métodos que se expondrán y explicarán a lo largo del informe.

Además, se generó una **visualización** de la **distribución del precio de cierre**, la cual mostró un patrón que puede ser útil para **identificar 'outliers'**. Sin embargo, como en la Ilustración 1 se puede llegar a observar, la distribución mostró un rango de valores de cierre que entra dentro de lo esperado para las acciones que componen el índice con el que se trabaja.




Ilustración 1: Distribución de precio de cierre en datos originales. Fuente: Elaboración propia.

El siguiente paso fue la **visualización** de las **series temporales** de todas las acciones, para poder visualizar la distribución de las ausencias. De esta manera, se observó que la mayoría se localizan en el 2021. Una vez analizados y visualizados los valores nulos, se definió una **función** la cual creaba tres columnas para almacenar los resultados de los respectivos **métodos de imputación** que se utilizaron. Los tres métodos utilizados para la imputación de los valores de la columna 'close' fueron '**interpolate**', y '**fillna**' introduciendo los métodos '**ffill**' y '**bfill**'.

Tras realizar la imputación con los tres métodos y compararlos como en la Ilustración 2 se observa, se decide seleccionar el método '**interpolate**' con el método '**linear**' para llenar los valores faltantes en las series temporales de precios de cierre de acciones de empresas del Dow Jones, ya que proporcionó una estimación más precisa en comparación con '**ffill**' y '**bfill**', debido a que estos últimos dos simplemente **replicaban** el **último valor** disponible antes del dato faltante o el **primero** después de este. Es decir, podían introducir **sesgos** significativos en las series temporales que afectasen a cálculos de rentabilidades y volatilidad posteriores.

Sin embargo, al **interpol**ar se calculó el valor faltante tomando en cuenta una **media** entre los puntos anterior y posterior, generando un valor que **sigue** más fielmente la **trayectoria natural del precio**. Por ello, con el objetivo propuesto se consideró mejor método que los demás.




Ilustración 2: Comparación métodos de imputación. Fuente: Elaboración propia.

Asimismo, se identificaron los días **festivos** de Estados Unidos y los **sábados** para pasarlos a valores nulos y posteriormente **interpolarlos**, ya que eran valores repetidos que afectaban también a la evolución del precio de los activos. Esta práctica se consideró importante ya que estos días el mercado estaba cerrado, por lo que se debía evitar tener valores iguales en el precio de 'close' entre un día y otro. Esto se realizó con la finalidad de obtener **más datos**, ya que, si bien es cierto que otra opción posible podría haber sido eliminar dichos datos al no ser reales, el caso del reto en el que se querían predecir 5 años a futuro con tan **poca información** como de la que se disponía, se decidió que era mejor no eliminarlos e interpolarlos.

Posteriormente se realizó un **ajuste de fechas** ya que los datos de las acciones no se encontraban en el mismo espacio muestral para poder realizar un correcto análisis. Para ello, se identificaron entre todos los datos de las acciones, la **fecha inicial** más **tardía**, para que todos empezasen desde el mismo momento, que vino a ser el día **2020-06-02** a las 00:00:00. Esa fecha inicial máxima se aplicó a todos los datos de las acciones, mientras que la fecha final no necesitó ningún cambio ya que de primeras todas las acciones tenían la **misma fecha final**. Al concluir con este proceso se realizó una comprobación para asegurarse de que todos los datos estaban completos. Finalmente se obtuvieron valores en 395 días totales de cada uno de los activos.

Cabe mencionar que durante el proceso de preprocesamiento se trabajó con una fuente de información externa como **'yahoo finance'**, únicamente para localizar los **'splits'** de las empresas que componen el índice y por ello poder realizar los ajustes necesarios y trabajar con datos más precisos (observar ejemplo en la Ilustración 3 e Ilustración 4). Se localizaron tres empresas que realizaron un 'split': *IBM*, *Apple* y *Merck & CO*.




Ilustración 3: Precios Apple previos a corrección por 'Split'. Fuente: Elaboración propia.




Ilustración 4: Precios Apple tras ajuste de 'Splits'. Fuente: Elaboración propia.

Capítulo 5: Selección de activos (AAPL, GS, MRK)

5.1 Descripción y justificación de criterios empleados

El primero de los **objetivos** del trabajo consistió en **crear una cartera compuesta por 3 activos** para valorarla posteriormente, y para ello se ha explicado el análisis seguido y los criterios empleados para seleccionar los activos. Para cumplir este objetivo, en principio se decidió crear la cartera teniendo en cuenta principalmente el **ratio de Sharpe** y la situación financiera de las empresas que mejor ratio pudieran proporcionar, junto con la mayor diversificación posible. Este ratio es muy representativo por que expresa la **rentabilidad obtenida por cada unidad de riesgo** soportado por un fondo o acción. Sin embargo, todas las combinaciones con mayor resultado en este ratio estaban correlacionadas positivamente entre ellas, y como en la cartera se **priorizó** mantener un **riesgo bajo** (dentro de las altas volatilidades que las empresas del índice habían experimentado en el periodo analizado), se **rechazó** la idea de **elegir tres activos correlacionados** directamente, ya que probablemente en el futuro se moverían en las mismas direcciones, y esto podía poner en peligro a la cartera. Por eso se escogió **diversificar la cartera** escogiendo activos correlacionados positiva y también negativamente en cuanto a precios y así poder diversificar.

5.2 Análisis y selección de activos

Para que la cartera se estabilizara se escogió una empresa con **correlación** de precios **negativa** que a su vez también tuviera **buenos indicadores financieros**, por ello, la empresa seleccionada fue **Merck Sharp & Dohme** (MRK), una de las multinacionales **farmacéuticas** con mayor volumen de ventas a nivel mundial. Se llevó a cabo esta estrategia ya que como anteriormente se ha mencionado, la intención era **diversificar el riesgo** mediante activos que se comportasen diferentemente en cuanto a precios, de forma que unas posibles pérdidas se compensasen con beneficios de los demás activos, teniendo en cuenta que esto pudiera resultar en reducir las probables ganancias en un escenario positivo. Habiendo escogido la primera empresa, se buscó dos empresas que pudieran combinar con esta y así conseguir el **mayor valor de ratio de Sharpe posible**, comprobando que estos activos tenían una volatilidad moderada, así maximizando el ratio una vez diversificada la cartera. **Para maximizar el rendimiento** sin tomar riesgos excesivos, se buscaron dos activos altamente correlacionados, y así diversificar el riesgo. Aun así, no fue el mejor ratio lo que reflejó la selección de las dos empresas que complementarían a **Merck Sharp & Dohme**.

Por tanto, una vez visto cuales eran las **mejores combinaciones** de **Merck Sharp & Dohme** con las demás empresas del índice se analizaron las empresas que formaban el top 10 de mejores combinaciones una a una y en base a su **situación financiera actual** y **previsiones** se seleccionó la composición de la cartera. Se creyó que esta era la **mejor manera** de **seleccionar** activos, en lugar de únicamente escogiendo los que mejor ratio de Sharpe obtenían, ya que es fundamental recordar que los **rendimientos pasados** de un activo o portafolio **no garantizan los rendimientos futuros**, por lo que solo analizar rentabilidades y volatilidades, sin más contexto, sería un análisis muy superficial y aleatorio. De esta manera, se seleccionaron los tres activos considerando no solo sus rendimientos históricos, sino también la **situación actual** de las empresas y proyecciones (en el 2021). Esto implicó un análisis detallado de su situación financiera, sus perspectivas y su resistencia a las fluctuaciones del mercado. Además, es importante anotar que solo se contaba con **datos de un año** para el análisis de los precios, que encima se veían **afectados** por un evento de **cisne negro** (COVID) lo cual limitó la capacidad de evaluar su comportamiento en el tiempo, obligando a analizar más aspectos.

Tras este proceso, las empresas seleccionadas para completar la cartera de activos fueron las estadounidenses **Goldman Sachs** y **Apple**. Estos dos activos mostraban una **correlación de precios alta positivamente**, con un coeficiente de 0.631629. Por otro lado, **Merck Sharp & Dohme**, mostraba una correlación negativa de -0.463311 con Goldman Sachs y -0.049753 con **Apple**. La **elección de los activos** se basó en varios factores, no solo en las **correlaciones** (variable de apertura 'close'), o el **ratio de Sharpe**, ya que también al igual que se buscó

diversificar la cartera en cuanto a riesgos, también se buscó hacerlo en cuanto a los **sectores** de las empresas seleccionadas. *Apple* diseña y produce equipos electrónicos y software y *Goldman Sachs* es líder global en servicios de banca de inversión, valores y gestión de inversiones. La **combinación** de estas tres empresas aportaba una **diversificación** en cuanto a **sectores** a la cartera, ya que incluía empresas de sectores tan diferentes como la **tecnología**, el sector **financiero** y el de la **farmacéutica**. Esto resultaba beneficioso para **reducir** el **riesgo**, ya que los distintos sectores responden de manera desigual a las condiciones del mercado. Además, *Merck* tendía a ser menos vulnerable a las fluctuaciones económicas debido a la demanda constante de productos farmacéuticos. Sin embargo, las tres empresas son **estadounidenses**, por lo que la cartera carecía de diversificación geográfica, ya que todos los activos dependían de la economía de un único país. Este aspecto, no obstante, era imposible de modificar debido a que los datos del índice eran proporcionados por BBVA.

Respecto a factores relacionados con la **macroeconomía**, los que afectarían a *Goldman Sachs* incluyen el estado general de la economía estadounidense (tasas de interés, por ejemplo), que influirían en la **demand**a de **servicios financieros y bancarios**. Por su parte, *Apple* podría verse afectada por **tensiones comerciales**, como las disputas entre Estados Unidos y China. En el caso de *Merck*, su valor podría estar condicionado por **una disminución en la inversión en investigación y desarrollo**, o por **regulaciones de salud** relacionadas con la aprobación y comercialización de productos farmacéuticos. En conclusión, al incluir un activo con correlación negativa y diversificar la **cartera** por sectores, es probable que esta resulte **menos volátil**, mostrando un **perfil más conservador y menos expuesto** a eventos externos.

Para asegurar de que las empresas escogidas eran una buena opción fue imprescindible analizar el **contexto económico** e informarse a partir de noticias y artículos de la situación que estaba viviendo cada empresa, para saber si *Goldman Sachs* y *Apple* eran financieramente una buena opción. En el artículo publicado por Daniel Martins, [8] se explicaban alguno de los indicadores que se deben de tener en cuenta si un inversor está interesado en invertir en *Apple* teniendo en cuenta que el precio de sus acciones se ha mantenido alrededor de 125\$ en los últimos meses. El crecimiento del EPS (beneficio por acción) de *Apple* convertía a la empresa en una inversión muy atractiva, ya que aumentó progresivamente, con un crecimiento interanual del 59%. Incluso en un plazo de 4 años, 2025, se esperaba un crecimiento anualizado de este valor del 13,4%, pudiendo aumentar *Apple* sus ingresos.

Por último, en su artículo, Jacob Mallinder [9] indicaba que la empresa *Goldman Sachs* registró ingresos récord en bancas de inversión en el primer trimestre de 2021, aclarando y disminuyendo los terrores que causó la pandemia en los inversores y mejorando las expectativas de los analistas *Goldman Sachs* logró un aumento del 73% en sus ingresos de banca de inversión, alcanzando los \$3.77 mil millones, su nivel más alto desde 2010. Este crecimiento se atribuye a un aumento global de actividades de banca de inversión, que alcanzaron un récord de \$39.4 mil millones en el primer trimestre, según datos de 'Refinitiv'. Además, *Goldman Sachs* anunció su expansión a Birmingham, donde planea contratar a "varios cientos" de empleados, comenzando por un departamento de ingeniería.

En cuanto al cálculo del **rendimiento** de la cartera compuesta, se hizo uso de métricas como la **rentabilidad y de la volatilidad**, teniendo en cuenta que los siguientes resultados de la cartera se han obtenido con una **distribución de pesos** entre los activos de **1/3 por empresa**. El resultado de la tasa de rentabilidad fue 0.2783, que mostró una rentabilidad muy buena. La **rentabilidad** significa que la inversión ha generado un retorno de **27%** sobre el capital invertido en un inicio. Por otro lado, para saber si una **volatilidad** con un resultado del **14.42%** es buena o no, hay que entender el contexto y también tener en cuenta el riesgo que se está dispuesto a tomar, ya que la volatilidad simplemente mide cuanto fluctúan los retornos de la cartera que se ha escogido en torno a la media. Normalmente, cuanto mayor es la volatilidad, mayor es el riesgo que se está tomando, pero teniendo en cuenta que la rentabilidad es bastante alta, la volatilidad resulta bastante moderada en comparación. Además, en comparación a los activos del índice en el 2021, un 14% era un valor bajo. Este resultado concordó con la intención de que esta cartera fuera más moderada y segura, gracias a la diversificación de sectores e incluyendo un activo con correlación negativa.

El ratio de Sharpe es una de las variables más importantes a la hora de analizar y valorar un fondo de inversión. Este ratio es tan importante porque el error de muchos inversores suele ser fijarse demasiado en las rentabilidades del fondo y no en los niveles de riesgo. Cuando la volatilidad del fondo de inversión es grande, se asumen más riesgos y por ese motivo el ratio de Sharpe es menor, a no ser que el rendimiento del fondo en concreto compense esa mayor rentabilidad. El resultado del ratio de **Sharpe** de la combinación de los activos APPL, GS y MRK fue de un **1,860**, que indicó que la cartera generó un **rendimiento positivo en relación al riesgo asumido**. Aunque el ratio de Sharpe fuera un resultado muy positivo era también vital considerar las condiciones del mercado y tener en cuenta el contexto económico.

A diferencia del ratio de Sharpe, **ratio de Sortino** emplea la **volatilidad negativa** en vez de la volatilidad total. Esto lo convierte en una medida más precisa para inversionistas que están preocupados únicamente por evitar las pérdidas. El resultado obtenido fue de **2.4421** lo que se consideró **bastante bueno**, ya que representó un perfil riesgo-retorno muy favorable, que es lo que se buscó con esta cartera. Después de elegir las empresas para la cartera, se crearon gráficos para analizar la situación económica y financiera de cada una. Esto permitió identificar las principales diferencias entre ellas y visualizar los resultados obtenidos de manera más clara.




Ilustración 5: Rentabilidad vs Volatilidad 10 mejores combinaciones de activos con MRK. Fuente: Elaboración propia.

La Ilustración 5 representa las **10 mejores combinaciones de carteras** que se encontraron combinando dos empresas con **Merck Sharp & Dohme**, ya que se buscó que la cartera fuera moderada al tener una empresa con una correlación negativa, pero con buenos indicadores financieros. Se puede observar como el punto rojo, que finalmente fue la **cartera que se escogió**, es el punto más alto del gráfico, y, en consecuencia, la cartera con **mayor rentabilidad**. Por otra parte, observando la volatilidad, se encuentra un poco por debajo que la media de la volatilidad de las distintas combinaciones, por lo que aparte de ser la más rentable, no se estaban tomando tantos riesgos al elegir esta opción. Este grafico es muy representativo debido que principalmente se escogió la cartera de activos con mayor ratio Sharpe, ratio que, en efecto, tenía en cuenta la rentabilidad y la volatilidad de un activo, buscando la rentabilidad más alta sin tomar riesgos excesivos e innecesarios.




Ilustración 6: Rentabilidad y riesgo de activos y cartera. Fuente: Elaboración propia.

La Ilustración 6 muestra la relación entre la volatilidad (eje x) y la rentabilidad (eje y) de varios activos individuales, *Goldman Sachs*, *Apple* y *Merck Sharpe & Dome*, que representan las tres empresas escogidas para crear la cartera, y por otro lado la misma cartera que se compuso. Este gráfico se centra en visualizar cómo se comportaba cada uno de los **activos** que componen la **cartera** individualmente y **compararlos** con la misma cartera. Cada una de las empresas se representa con su logo para poder ser identificado más fácilmente y que sea más representativo. Por un lado, tenemos a **Merck Sharp & Dohme**, que muestra una rentabilidad media-baja del 17% y una volatilidad bastante baja, solo del 15%, aportando mayor seguridad a la cartera siendo el activo menos volátil y el más ‘estable’, caracterizándose por poseer el menor nivel de riesgo entre los activos. Después, se puede observar el logo de **Apple** que se encuentra en un punto bastante alto respecto a la rentabilidad, ya que tiene una tasa de rentabilidad de 0.68, y bastante alto respecto a la volatilidad, con una tasa de volatilidad de 0.23. Por último, en el punto más alto de rentabilidad, con un 82%, se encuentra **Goldman Sachs**, que por otra parte también es el activo que mayor volatilidad representa, con una volatilidad del 25%, ligeramente más alta que la de **Apple**. A pesar de que **Goldman** sea la empresa con mayor volatilidad, la relación rentabilidad-volatilidad sigue siendo muy buena y sigue siendo una opción adecuada para invertir. La volatilidad del **Goldman Sachs** es 1.09 veces mayor que la de **Apple**, pero la rentabilidad del banco de inversiones es 1.21 veces mayor, por lo que se puede suponer que es la mejor inversión aun teniendo en cuenta la su ‘alta’ volatilidad.

Por otra parte, también se representó la cartera creada representada en el gráfico. Se podría decir que se asemeja mucho a los resultados de **Merck Sharp & Dohme**, pero mejorados en cuanto a rentabilidad, lo que tiene sentido, debido al enfoque moderado que se escogió darle a la combinación de activos. La volatilidad es casi igual que esta empresa, aunque ligeramente menor, con una tasa de volatilidad de 0.144, pero la cartera escogida tiene una mayor rentabilidad que esta empresa, lo que supone un mayor ratio de Sharpe también. La cartera hubiera generado un retorno de 30% sobre el capital invertido en un inicio durante el periodo analizado, lo que supone un resultado bastante bueno. Con este gráfico se vuelve a representar claramente la finalidad de buscar la mayor rentabilidad posible sin que la volatilidad se exceda.




Ilustración 7: Frontera eficiente de la cartera. Fuente: Elaboración propia.

En la Ilustración 7 que se muestra arriba, se puede observar una **frontera eficiente**. La frontera eficiente en el mundo financiero se utiliza para **optimizar las inversiones** equilibrando la rentabilidad y la volatilidad de los activos, maximizando el rendimiento. La **distribución de pesos** en una frontera eficiente se refiere a la manera en la que se asigna el capital entre los diferentes activos. En el caso de la cartera de activos seleccionada, se realizaron varias combinaciones de diferentes distribuciones de los pesos de cada activo, para optimizar la relación rentabilidad-riesgo.

Las estrellas azul y roja en la frontera eficiente representan portafolios óptimos, donde ningún otro portafolio tiene mayor rentabilidad para la misma volatilidad o menor volatilidad para la misma rentabilidad. Todos los demás puntos que no estén representados por una estrella son ineficientes comparados con estos. En cada uno de los casos se **distribuyeron los pesos aleatoriamente** de manera distinta con el fin de mejorar la diversificación.

Si el objetivo de la inversión fuera buscar el **mayor rendimiento** de los activos arriesgando lo mínimo posible, entonces la mejor opción sería la **estrella roja**. Al contrario, si el objetivo fuera **minimizar los riesgos**, y dentro de eso, intentar sacar rendimiento a la cartera, la opción más óptima sería la **estrella azul**. En los dos casos se redujo riesgo sin sacrificar rendimiento, pero tenían puntos de vista distintos.

El punto que representaba la menor volatilidad en la cartera eficiente tiene una tasa de volatilidad del 0.12 y una tasa de rentabilidad del 0.15. Teniendo en cuenta estos dos valores, se calculó que el ratio de Sharpe es de 1.09. En este caso los pesos se distribuyeron de la siguiente manera: **Apple** un 0.19874142, **Goldman Sachs** un 0.17951807, y por último **Merck Sharp & Dohme** un 0.62174051.

Por otro lado, el punto que representa mayor rentabilidad en el gráfico tiene una tasa de rentabilidad de 0.43 y una tasa de volatilidad de 0.18. El ratio de Sharpe en este punto es de 2.27, distribuyendo los pesos de esta forma: **Apple** un 0.40903286, **Goldman Sachs** un 0.58835204, y por último **Merck Sharp & Dohme** un 0.0026151.

En los dos casos se obtuvo un ratio de Sharpe considerablemente bueno, pero con los pesos diversificados en el punto de mayor rentabilidad la volatilidad solo subió un 24% del 14.42% inicial

al 18% posterior y la rentabilidad aumentó en un 54% del 27.83% inicial al 43%. Como la cartera de activos ya era de por sí una cartera bastante conservadora, no hubiera sido tan arriesgado escoger el **punto con mayor ratio de Sharpe y asumir la volatilidad** ante el mayor porcentaje de rentabilidad. Desde un punto de vista financiero este resultado sería el óptimo, pero para poder hacer el cálculo de la prima mediante la formula cerrada, los pesos de la cartera se dividieron en tres partes iguales.




Ilustración 8: Rentabilidad y riesgo de activos y cartera con pesos optimizados. Fuente: Elaboración propia.

La Ilustración 8 representa los diferentes activos escogidos y la cartera, pero esta vez, se **optimizó el ratio de Sharpe** de la cartera utilizando la **frontera eficiente** mencionada anteriormente y distribuyendo los pesos de distintas maneras. Se ha representado el punto de la cartera eficiente con mayor rentabilidad asumiendo el mínimo riesgo posible, ya que era la mejor opción financiera. Se puede visualizar cómo en este caso la volatilidad aumentó ligeramente, pero la rentabilidad subió mucho más en proporción. De esta forma se rectificó la utilidad de realizar una frontera eficiente para optimizar los resultados.

5.3 Conclusiones

La cartera generada no solo minimizó riesgos innecesarios, sino que además ofreció una **rentabilidad adecuada en relación con el riesgo asumido**. Este enfoque se ajustó al objetivo de construir una cartera estable y adecuada para escenarios de mercado inciertos.

Respecto a la **proyección futura** de las empresas del índice 'Dow Jones', uno de los principales temores de los inversores es la potencial **recesión** de la economía **estadounidense**, desencadenada por diferentes razones, entre las cuales podría estar, el conflicto bélico en Israel o el 'overpricing' que está viviendo el mercado.

En el contexto de la **cartera** creada, se puede prever que el sector financiero sería el que más sufriría en el escenario negativo planteado previamente. En particular, la banca (*Goldman Sachs*) probablemente enfrentaría efectos negativos debido a la repulsión al peligro de los inversores, lo que podría parar un hipotético crecimiento económico. En contraste, la industria farmacéutica tiende a ser más resiliente ante escenarios económicos de este tipo, por lo que no se anticipa un cambio significativo en el valor de las acciones de *Merck*. Por último, el sector que más destaca hoy en día es el de la tecnología, que va ganando importancia a una velocidad considerable. Esto puede llevar a suponer que **independientemente de factores externos**, este sector seguiría creciendo y revalorizándose. Gracias a la **diversificación** de la cartera, aunque no se

pueda predecir el futuro, se pudo **asegurar** con gran seguridad la **estabilidad** de esta en los próximos años.

5.4 Descripción teórica opciones financieras

Las **opciones financieras** otorgan el **derecho**, sin la obligación, de **comprar** o **vender** un **activo subyacente** a un **precio acordado**, bien en cierta **fecha** acordada o dentro de un **período** definido. Desde una perspectiva de inversión, resultan **interesantes** no solo porque ofrecen **protección** contra variaciones adversas en el precio, sino también porque pueden generar **beneficios** significativos. Las opciones **europeas**, por ejemplo, solo se pueden ejercer en la fecha de vencimiento, mientras que las opciones americanas permiten esta flexibilidad en cualquier momento hasta su vencimiento. En contraste, las opciones **asiáticas**, que también deben ejercerse al final del período, calculan su precio de ejercicio usando el promedio del valor del activo subyacente en el período definido, lo que les otorga características únicas.

Dentro de las **alternativas** financieras, las opciones de tipo '**call**' brindan el **derecho a adquirir** el activo, mientras que las opciones '**put**' otorgan el **derecho a venderlo**. También existen opciones de **barrera**, cuyo valor está condicionado a que el precio del activo alcance determinados niveles, y las opciones '**lookback**', que permiten basar el ejercicio en el mejor precio alcanzado, lo que puede ser especialmente atractivo en situaciones de alta volatilidad.

En el contexto de las **opciones asiáticas**, el cálculo de su valor se realiza utilizando el **promedio** del precio del activo subyacente durante el tiempo previo a su vencimiento (en este caso, mediante una media geométrica). Este promedio **disminuye** la **volatilidad** del precio de ejercicio, ya que evita que un único precio extremo en un momento determinado afecte el resultado final. Esta característica es valiosa cuando se busca **reducir** la **incertidumbre** en la inversión, proporcionando una herramienta de cobertura más estable y menos expuesta a cambios bruscos.

En este trabajo, se analiza una **opción asiática con media geométrica**, la cual destaca como una opción **eficiente** para **simular** escenarios de mercado con el método **Montecarlo**. Su capacidad para reducir la volatilidad la convierte en un instrumento financiero ideal para proyectar resultados financieros con mayor precisión y estabilidad, haciéndola muy atractiva para estrategias de inversión que prioricen el control de riesgo y la consistencia en mercados volátiles.

5.5 Descomposición de series temporales y modelización de la volatilidad

Uno de los objetivos dentro del proyecto era realizar la modelización y **predicción de la volatilidad** de las tres empresas que conforman la cartera de inversión, en este caso *Golden Sachs*, *Apple* y *Merck Sharp & Dohme*. La volatilidad muestra la variabilidad de los precios de un activo y muestra el riesgo en el cambio de su valor, con lo cual, poder modelizarla y predecirla es clave, ya que ayuda a los inversores a anticiparse a cambios en los precios de los activos para planificar de una manera correcta las inversiones y poder maximizar sus beneficios.

Para llevar a cabo el objetivo se realizó un **análisis** de las series temporales de las acciones de la cartera para poder realizar los modelos. Cabe destacar que los modelos se crearon con los respectivos residuos de las series temporales, con lo cual, al realizar la descomposición de las series donde se diferenciaban la tendencia, la estacionalidad y los residuos de la serie, se guardaron los residuos para poder llevar a cabo los modelos con datos sin tendencia, ya que la estacionalidad, las series de por sí, no la presentaban.

La razón por la cual se utilizaron los **residuos** de las series temporales para modelizar es porque los residuos son las partes de las series temporales que representan las variaciones **no explicadas** y que no tienen una estructura clara, los cuales permiten estimar de manera más **precisa** la volatilidad y sus variaciones **inesperadas**.

Una vez obtenidos los residuos de dichas acciones, se procedió a analizar mediante diferentes **test** si las series temporales eran **estacionarias**. Para ello se probaron los test de ADF y KPSS, test de raíz unitaria, los cuales dan por hecho que el residuo de la serie es estacionario comprobando solo si la serie es **estacionaria en tendencia**. Por esta razón, se realizaron

también los test de 'White', 'Breusch-Pagan' y 'Goldfeld-Quandt', con el fin de comprobar si la varianza de los residuos de las series es constante o no y poder afirmar si las series presentan **heterocedasticidad**, es decir, que la varianza de los residuos no sea constante, que es clave para poder llevar a cabo la modelización de la volatilidad. A continuación, se muestran los p-valores de los test de raíz unitaria y los de heterocedasticidad en la Tabla 2:

Tabla 2: Resultados de test de estacionariedad y homocedasticidad de las tres acciones.

	Test estacionarios en tendencia		Test heterocedasticidad		
	ADF	KPSS	White	Breusch-Pagan	Goldfeld-Quandt
GS	0.0118	0.01	0.1194	5.3560e-08	0.3283
AAPL	0.0666	0.0566	4.1200e-05	1.6611e-06	0.0002
MRK	0.0914	0.0457	1.0592e-06	0.0388	6.4875e-07

Para que una serie presente **heterocedasticidad**, los tres valores de los test de esta tienen que dar valores menores que el valor de significancia de 0.05, los cuales **AAPL y MRK cumplen**, pero **GS no**. Por otro lado, cabe mencionar que los test de raíz unitaria indican que GS es estacionaria en diferenciación, que AAPL es estacionaria en tendencia y que MRK no es estacionaria en tendencia. Como los test lo indican, **GS no puede ser modelizada** ya que no muestra heterocedasticidad, debido a que la varianza de sus residuos es constante, y no muestra cambios en la varianza que puedan ser modelizados para poder llegar a capturar la volatilidad de los datos. Una vez comprobados los test, se procedió a comenzar con la parte de modelización con los activos de AAPL y MRK, para lo cual se realizó una división entre datos de 'train' y 'test' de cada acción, con datos desde el "2020-06-03" hasta el "2020-12-21" para el 'train' y desde el "2020-12-22" hasta el "2021-07-01" para el 'test'.

Para crear los modelos se utilizaron los **modelos ARCH y GARCH**, ya que cuando una serie temporal presenta volatilidad, tendremos una serie no estacionaria y con lo cual modelos como AR, MA o ARIMA, no son adecuados al no tener en cuenta la homocedasticidad. ARCH y GARCH son modelos que capturan cómo la varianza de los residuos varía con el tiempo y llega a depender de valores previos. ARCH utiliza valores previos de los residuos para predecir la volatilidad, mientras que GARCH añade a esta una media móvil de las varianzas previas. Para poder elegir los valores adecuados de 'p' y 'q' para los modelos, se visualizaron las gráficas **ACF**, la cual representa los coeficientes de autocorrelación calculados teniendo en cuenta una serie de desfases, y **PACF**, que muestra la autocorrelación parcial de los residuos al cuadrado de los dos activos.




Ilustración 9: Gráficos ACF y PACF de el residuo al cuadrado de Apple. Fuente: Elaboración propia.

La Ilustración 9 muestra los gráficos ACF y PACF de **APPL** e indica que **no se deberían de realizar modelos GARCH** ya que la elección de la 'q' no sería adecuada debido a que no bajan de manera brusca los valores en el gráfico ACF, mientras que en el PACF los valores bajan de manera brusca en el punto 2, sugiriendo un modelo ARCH ($p = 2$).




Ilustración 10: Gráficos ACF y PACF de el residuo al cuadrado de MRK. Fuente: Elaboración propia.

Por otro lado, los gráficos de **MRK**, expuestos en la Ilustración 10, **tampoco siguieren** un modelo **GARCH** debido a su poca brusquedad al bajar a medida que pasa el tiempo, mientras que el PACF al igual que en Apple sugiere un modelo ARCH ($p = 2$). Como se puede observar en las tablas de los resultados del [Apéndice II](#), ningún modelo es válido en ambos activos, con lo cual **ningún modelo** se puede utilizar para **predecir la volatilidad** ya que la predeciría de manera sesgada capturando patrones de volatilidad inexistentes o no fiables introduciendo ruido en las predicciones. En resumidas cuentas, hay **casos** en los que la **volatilidad no se puede llegar a predecir** debido a diferentes factores como ocurre en este caso. Puede ser que no haya la suficiente cantidad de datos o que la calidad de estos no sea lo suficientemente buena, pero en este caso, como previamente se ha mencionado, se debe a que **no consigue captar patrones** de volatilidad como para poder generar un modelo válido.

Capítulo 6: Estimación de prima de productos financieros

6.1 Simulación de Monte Carlo

Con el objetivo de simular el precio de la **evolución** de los precios de los **tres activos** elegidos que conforman la cartera se ha hecho uso de las simulaciones de Montecarlo. A partir de los resultados de cada simulación, se calcularon los 'payoffs' para después calcular la prima (precio) de la opción. Para calcular esta prima se realizaron **100000 simulaciones**, ya que se consideró que a partir de este valor las mejoras no eran tan relevantes y el **costo computacional** aumenta considerablemente.

Cabe destacar que la simulación consta de **20 pasos temporales**, sin embargo, los **5 primeros** pasos son **comunes** para todos los activos, es decir, todas las trayectorias son iguales en estos primeros 5 pasos y es en los 15 siguientes donde se diferencian. De esta manera, la **salida** que se obtuvo presentó unas dimensiones de **100000 simulaciones** con **20 pasos** temporales, separados **para cada uno** de los **activos**.

En primer lugar, se creó una **matriz de correlaciones 3x3** a partir de los datos, los cuales debían seguir una **misma frecuencia muestral** (datos diarios). Para realizar la simulación se crearon **datos aleatorios** que **replicaban** la **correlación** de los datos originales. Para ello, se aplicó la **descomposición** de 'Cholesky' sobre la matriz de correlaciones. Además, se utilizaron las **volatilidades** obtenidas para cada una de las empresas y se definieron otros parámetros, entre los que se encontraban la **tasa de riesgo libre** (1%), el **valor inicial "S0"** y el **precio de ejercicio** que se definió con un valor de 3. En lugar de utilizar valores absolutos (como precios reales de mercado), se optó por un **valor inicial normalizado de "1"** para cada activo. Esto facilitó el análisis y permitió enfocarse en las variaciones relativas de los activos a lo largo del tiempo, eliminando cualquier sesgo o escala introducido por los precios iniciales absolutos.

Con base en estos **parámetros** definidos, se llevaron a cabo las simulaciones. En primer lugar, se generaron **variables aleatorias**, las cuales luego se utilizaron para **calcular** los **coeficientes** que se multiplican por los precios en cada instante. De esta manera, se obtuvo una matriz que refleja el valor de los activos en cada momento temporal. En la Ilustración 11 se pueden observar las **diferentes trayectorias** que cada activo tomó. Se puede comprobar que la empresa *Merck Sharpe & Dohme* es la que obtuvo los valores más pequeños, mientras que *Goldman Sachs* y *Apple* obtuvieron trayectorias bastante parecidas, debido a su mayor volatilidad.




Ilustración 11: Gráfico de las trayectorias de la simulación de Monte Carlo. Fuente: Elaboración propia.

Una vez se obtuvieron estos **precios** se procedió a **calcular el** valor de la opción asiática. Para lograr obtener dicho precio, se empleó la **media geométrica** de los precios por **cada simulación** para así calcular el 'payoff', el cual se define como el valor máximo entre 0 y la suma de los valores de los tres activos tras restarles el el precio de ejercicio:

$$\max \left(\sum (\text{precios por activo}) - K, 0 \right)$$

A partir de los 'payoffs' obtenidos calculó la **prima** de la cartera mediante la media aritmética de los mismos. Sin embargo, como el **objetivo** era predecir el valor de la prima en el **presente**, se **actualizó** este valor a valor presente. El precio de la opción que se obtuvo mediante la simulación visualizada en la Ilustración 11 fue de **0.1486966**, representando este número el **precio** de la prima en **términos relativos** al valor inicial normalizado de los activos.

6.2 Implementación y comparación de métodos

Tras calcular el valor del 'payoff' y de la cartera en base a métodos matemáticos como la simulación de Montecarlo y la función cerrada de BBVA, se procedió a **entrenar** y **comparar** diferentes **modelos** de 'deep learning', en este caso **redes neuronales recurrentes**, para comparar sus resultados con los de los métodos anteriores y ver cómo se ajustan, no solo a la predicción del 'payoff' en el último paso, sino en los pasos anteriores. Así, terminado este proceso se podrá decidir si **merece la pena** el **ahorro** del **coste computacional** que supone utilizar **redes** neuronales respecto a utilizar el método de Montecarlo.

Las **redes neuronales recurrentes (RNNs)** son particularmente útiles en problemas de series temporales como la predicción de precios de activos financieros, porque están diseñadas para **capturar dependencias temporales**. Esto significa que las RNNs pueden aprender patrones secuenciales en los datos, algo esencial cuando se trabaja con datos de precios, donde los valores actuales dependen de los valores previos. En este caso, se alimentará la RNN con una **secuencia de precios** generada para cada acción a través de **Montecarlo**, donde la red podrá aprender los patrones de cambio en los precios y cómo estos influyen en el valor final del derivado. La red entonces intentará prever el 'payoff' de la opción en el último paso, utilizando la secuencia de precios a lo largo del tiempo como contexto.

Para abordar el reto de la valoración de un derivado financiero, en este caso, una opción call asiática sobre una cartera compuesta por tres acciones del índice Dow Jones, se decidió implementar modelos de redes neuronales recurrentes, específicamente **LSTM** ('Long Short-Term Memory') y **GRU** ('Gated Recurrent Unit'). Ambos modelos destacan por su capacidad para **capturar** y **analizar patrones** en **series temporales**, lo cual resulta fundamental en la modelización de precios de activos financieros que varían en el tiempo. Además, en comparación con métodos tradicionales, los modelos LSTM y GRU son menos susceptibles a la pérdida de información en secuencias prolongadas, lo que permite que capten de manera más precisa las dinámicas complejas en los precios de los activos subyacentes en la opción.

Para ello, **primero** se testearon **3 modelos básicos**, para así poder **estudiar** el **comportamiento** de estos modelos, y **luego buscar optimizar hiper parámetros**, así como el optimizador, la función de activación, neuronas por cada capa y el número de capas ocultas, que son los que se ha creído que son los que mejor pueden optimizar el funcionamiento de los modelos, ya que cada uno de estos parámetros tiene un impacto directo en la eficiencia computacional. Al ajustar y optimizar estos aspectos, el **objetivo** es lograr que el modelo ofrezca **predicciones precisas** sin requerir recursos computacionales innecesariamente altos.

Se generaron por tanto una clase para el 'early stopping', que, con una paciencia de 5, parará el modelo cuando la pérdida de la validación del modelo no mejorase. También una función que entrena al modelo y en base a épocas calculase la pérdida con los datos de entrenamiento y testeo y lo devolviera. Tras separar los datos, expandir las dimensiones de la columna a predecir y pasarlos a tensor, se procedió a probar 3 modelos iniciales:

1.- Modelo LSTM 1: Este modelo utiliza una arquitectura LSTM con 2 capas y 12 unidades ocultas. Después de pasar los datos por la LSTM, se usa una capa densa que genera la salida final basada solo en el último paso de tiempo, y se incluye la activación 'ReLU' en la capa final.

2.- Modelo LSTM 2: Este modelo es más complejo que el anterior al incluir 32 unidades ocultas en la capa LSTM y funciones adicionales para mejorar la robustez y generalización. Incluye normalización por lotes ('BatchNorm') y regularización por 'Dropout'(0.15) tras la capa LSTM y en cada capa densa. La arquitectura densa consiste en dos capas intermedias con 64 y 32 neuronas respectivamente, cada una seguida de normalización y 'Dropout'.

3.- Modelo GRU: Este modelo se basa en una arquitectura GRU con 2 capas y 32 unidades ocultas, similar a LSTMModel2 en estructura. Las capas GRU, al ser más simples que las LSTM, suelen ser computacionalmente más eficientes sin sacrificar demasiado la capacidad de modelado. Incluye normalización por lotes y 'Dropout' para reducir el sobreajuste y mejorar la capacidad de generalización. También cuenta con dos capas densas intermedias con 64 y 32 neuronas cada una, con activación 'ReLU' en cada paso.

Cabe mencionar que los 3 modelos se entrenaron en 20 épocas con un 'learning rate' 0.001 y 'gradient clipping' 0.01. Así, se buscó un **equilibrio** entre la **capacidad** de **aprendizaje** del modelo y la **eficiencia computacional**:

1.- Número de épocas (20): Al entrenar por 20 épocas, se permite que el modelo ajuste sus pesos de manera gradual. Además, el uso de 'early stopping' con paciencia de 5 asegura que el entrenamiento se detenga cuando el modelo deja de mejorar, ahorrando tiempo de cómputo innecesario, pero con un margen amplio.

2.- Learning rate (0.001): Este valor balancea la rapidez con la que el modelo ajusta sus parámetros. Un valor de 0.001 es un estándar común para modelos de redes neuronales profundas, ya que permite convergencia sin oscilaciones y evita caer en mínimos locales.

3.- Gradient Clipping (0.1): Esta técnica limita el valor máximo que pueden alcanzar los gradientes durante el entrenamiento. En modelos de tipo recurrente, como LSTM y GRU, el problema de gradientes explosivos es frecuente, especialmente en secuencias largas.

Si bien es cierto que estos hiper parámetros se podrían optimizar, teniendo en cuenta que se seleccionaron con un criterio inicial correcto y los buenos resultados iniciales logrados con ellos, se decidió trabajar con ellos y buscar optimizar otros hiper parámetros que se explicarán más adelante. Los resultados obtenidos fueron los expuestos en la Tabla 3.

Tabla 3: Comparación error y ajuste modelos iniciales.

	R2	MSE	MAE
LSTM 1	0.9951	0.0000827	0.008401
LSTM 2	0.9664	0.0005722	0.020508
GRU	0.7851	0.0036641	0.055168




Ilustración 12: Comparación predicciones y valores reales modelos iniciales. Fuente: Elaboración propia.

Tal y como se observa en la Tabla 3 y la Ilustración 12, los resultados obtenidos muestran que el **modelo más simple**, en este caso **LSTM**, obtuvo los **mejores** valores en todas las **métricas** (R^2 , MSE, y MAE), lo cual indica que, en este caso, una arquitectura más sencilla fue suficiente para capturar la complejidad de los datos y hacer predicciones precisas. Esto sugiere que el modelo más simple no solo es computacionalmente más eficiente, sino que también generaliza mejor en este contexto, evitando el sobreajuste que podría aparecer en arquitecturas más complejas. Por tanto, tras esta comparación inicial, se buscó **generar un modelo optimizado** mediante la comparación de combinaciones de hiper parámetros mencionados anteriormente:

1.- Neuronas en capas ocultas ('hidden_sizes'): Se probaron configuraciones de **12** y **24** unidades ocultas para evaluar el impacto de la capacidad del modelo sobre los datos. Un modelo más simple podría evitar el sobreajuste, mientras que un modelo más complejo podría mejorar la precisión.

2.- Número de capas ('num_layers'): Los modelos con más capas pueden captar mejor las relaciones temporales complejas, pero a costa de mayor complejidad y tiempo de entrenamiento. Se probó con **1, 2 y 3** capas.

3.- Activaciones: Se probaron diferentes funciones de activación (**'ReLU'**, **'LeakyReLU'**, **'Sigmoid'**) para explorar cómo afectan la convergencia y la precisión, ya que cada función tiene ventajas específicas en términos de estabilidad y capacidad de aprendizaje, seleccionando estas 3 en un inicio debido a diferentes razones. 'ReLU' principalmente por su simplicidad y eficiencia computacional y porque ayuda a que el modelo aprenda relaciones complejas en los datos de manera rápida y estable. 'LeakyReLU' ya que es una variante de 'ReLU' que permite valores negativos (al introducir una pendiente pequeña en el área negativa), evitando que las neuronas "mueran" por completo, lo cual mejora la robustez y flexibilidad del modelo en comparación con 'ReLU' en el caso de predicciones negativas del 'payoff'. Por último, 'Sigmoid', ya que el 'payoff' en las predicciones es generalmente un valor entre 0 y 1, y esta función de activación también limita las salidas entre 0 y 1, proporcionando un valor acotado y evitando resultados extremos que no tengan sentido.

4.- Optimizadores: Usar ‘Adam’ y ‘SGD’ permite comparar la velocidad de convergencia y la estabilidad en el aprendizaje, ayudando a identificar el optimizador que mejor se ajusta a la tarea. Adam, con su adaptabilidad en la tasa de aprendizaje, suele ofrecer una convergencia rápida y estable en problemas no lineales, mientras que SGD, aunque puede requerir más tiempo para converger, tiende a generalizar mejor en algunos casos al reducir la posibilidad de caer en mínimos locales.

Se testearon **36 modelos** diferentes, en los que se probó cada combinación de hiperparámetros diferente. Los resultados obtenidos (Mejores 3 modelos según error) son los siguientes:

Tabla 4: Mejores 3 modelos según MAE y MSE.

	MAE	MSE
Hidden size: 24, Layers: 3, Activation: Sigmoid Optimizer: Adam	0.0017	0.000005
Hidden size: 12, Layers: 2, Activation: LeakyRelu, Optimizer: Adam	0.0019	0.000007
Hidden size: 24, Layers: 2, Activation: LeakyRelu, Optimizer: Adam	0.0020	0.000006

Como en la Tabla 4 se expone, los **resultados** fueron **excelentes** y las **diferencias** en cuanto a **error** y **ajuste** entre modelos **mínimos**. Por ello, se decidió seleccionar como modelo para predecir el ‘payoff’ un **LSTM** que cuenta con **2 capas ocultas**, **12 neuronas** por capa, optimizador ‘Adam’ y activación ‘LeakyReLU’. Se creyó que un error tan ligeramente superior no suponía ningún problema, sobre todo teniendo en cuenta que se obtuvo ese error de la simulación específica generada con Montecarlo, pero que las métricas podrían cambiar según la simulación, manteniéndose igual de bajas, pero quizás cambiando el orden.

Fue la combinación de los **hiper parámetros** la que **justificó** la **elección** del modelo, y no el modelo con menos error. Este modelo contaba con menos capas y neuronas, lo que significa que es **menos complejo**. Una estructura más simple no solo facilita el entrenamiento, sino que también puede resultar en un **mejor rendimiento** en términos de generalización, y **evitar sobreajuste**. Además, en el contexto de modelos financieros, donde los ‘payoffs’ pueden incluir valores negativos (por ejemplo, en inversiones perdedoras), el uso de ‘LeakyReLU’ puede proporcionar una **ventaja**, ya que a diferencia de la función ‘ReLU’ estándar, que establece a cero cualquier entrada negativa, ‘Leaky ReLU’ permite que una pequeña fracción (por ejemplo, 0.01) de esos valores negativos pase a través de la función. Ante ‘Sigmoid’, se gana eficiencia computacional, y se cree que ante los resultados expuestos es lo que se debería priorizar.

En resumen, aunque el modelo con menor MAE (‘Mean Absolute Error’) podría parecer la opción óptima a primera vista, las ventajas que ofrece la estructura más simple, la activación ‘LeakyReLU’ y la capacidad de manejar mejor los valores negativos hicieron que la opción seleccionada fuera una elección más robusta y aplicable en el contexto del reto actual. Los **resultados** fueron **excelentes** al **entrenar** el modelo (Ilustración 13) y al probarlo con **datos nuevos** (Ilustración 14). Se exponen todos los modelos con sus métricas de error y ajuste en el [Apéndice I: Comparación resultados modelos testeados](#).




Ilustración 13: Evolución pérdida en 'train' y 'test' con modelo definitivo. Fuente: Elaboración propia.




Ilustración 14: Predicciones y valores reales con modelo definitivo. Fuente: Elaboración propia.

Por último, una vez entrenado y generado el **modelo** definitivo, se dio pie a la **comparación del rendimiento** de este y de la **formula** cerrada de BBVA para predecir la prima calculada por Montecarlo, no solo introduciéndole 20 pasos, ya que sabemos que así funciona bien, sino que reduciendo los **pasos** con los que predice con la red comparando sus predicciones con los resultados de la fórmula y de Montecarlo. El objetivo fue, por tanto, **evaluar la eficacia** de la red neuronal en función de los pasos temporales considerados durante el entrenamiento, comparando la prima debido a que la formula devuelve la prima. Para ello, no había más que actualizar los resultados de la simulación de Montecarlo y las redes al punto 0, y ver a partir de que paso dejan de ser eficientes las redes, para poder ver hasta que horizonte temporal sirven estos métodos en busca del **balance** entre la **eficiencia computacional** que suponen respecto a la **precisión** que se pierde.

Para ello, se inicializó un **bucle** que iba desde 20 pasos hasta 1. Iniciada la iteración, primero de todo, lo que se realizó era la **predicción** de la prima mediante la **fórmula cerrada** de BBVA, guardando el valor obtenido. Después, se realizó una **predicción** con el **modelo LSTM** utilizando

como input **datos nuevos** de las trayectorias obtenidas de la simulación de **Montecarlo**, pero **únicamente** con **información** hasta los **pasos** sobre los que se iteró (Se comienza con 20 y la última iteración se entrenará únicamente con 1). En cada iteración se calculó la **media** de todos los '**payoffs**' obtenidos y se **actualizó** al punto 0 para **obtener** la **prima**. Se utilizaron estos datos nuevos extraídos de la primera simulación de Montecarlo en lugar de realizar una nueva simulación debido a que, como los primeros 5 puntos de Monte Carlo se generan aleatoriamente, generar una nueva simulación no era una opción válida.




Ilustración 15: Comparación predicción de prima mediante 3 métodos con distintos pasos temporales.

Fuente: Elaboración propia.

Capítulo 7: Conclusiones

Tal y como se observa en la Ilustración 15, la **red neuronal** **perdió** su **eficiencia** según se realizaron las predicciones con **menos pasos temporales**. Conforme se disminuyó la cantidad de pasos temporales en los datos con los que se predecía, la prima estimada por las redes comenzó a distanciarse gradualmente de la prima calculada utilizando la fórmula de BBVA, a la que debería aproximarse. Se podrían optimizar las redes si se entrenará el modelo cada vez con los respectivos pasos temporales con los que se predecirá, pero carecería de sentido ya que el objetivo es saber si son fiables a menor ventana temporal de datos. Por ello, el análisis realizado confirma que, si se busca **reducir** los **pasos** temporales para **optimizar** el **tiempo** de cómputo, se **sacrifica precisión** en las predicciones de la **red neuronal**.

A lo largo del proceso de este proyecto, tras **seleccionar** y examinar financieramente una **cartera** que incluye tres activos del índice Dow Jones (Apple, Goldman Sachs y Merck), creando por tanto un **índice** con **bases sólidas** que puede generar ingresos en un futuro, se desarrolló un **modelo de simulación de Monte Carlo**, una metodología es intensiva en recursos computacionales, pero que proporciona una **estimación sólida** para calcular el precio de una opción sobre estos tres activos. Se ha comprobado que las **redes neuronales** son una herramienta **excelente** que mediante las trayectorias generadas por Montecarlo pueden predecir el **precio** de las opciones con gran acierto. Sin embargo, a medida que **reduce la ventana de datos**, la mejor opción acaba siendo la **formula cerrada de BBVA**.

Por tanto, con la totalidad de los datos, son una gran opción, pero lo **interesante** en este caso es la **predicción de los precios a futuro**, por lo que, aunque optimizan recursos, las **redes neuronales** **no** se **adaptan** muy bien a la **problemática** inicial de este reto. BBVA, sin embargo, podría aprovechar **redes neuronales** en **contextos** donde los **modelos tradicionales** son **menos efectivos** o en situaciones donde se requiere una mayor adaptabilidad a patrones complejos y no lineales. Por ejemplo, para casos de predicción del riesgo crediticio, detección de fraudes o predicción de demanda de productos financieros. En cuanto a la valoración de opciones, se propone a BBVA **desarrollar** un **sistema** que **ajuste automáticamente** la **ventana temporal** en función de la volatilidad del mercado o de los requisitos específicos de predicción. Esto permitiría mejorar la **precisión** del **modelo** cuando se requiere un análisis a corto plazo o aumentar la eficiencia computacional en períodos de estabilidad.

En cuanto a la **cartera** seleccionada, **excluyendo** eventos de **cisne negro** que son imposibles de predecir incluso con el análisis más riguroso, las perspectivas son positivas. Basándonos en el **análisis** exhaustivo de las empresas seleccionadas y sus sectores, así como en la rentabilidad y volatilidad observadas, y teniendo en cuenta la **proyección** de la **economía** estadounidense, se espera que esta cartera tenga un **rendimiento favorable a largo plazo**. La inversión en **renta variable destaca**, especialmente en activos de calidad, a ofrecer buenos resultados a medida que el **horizonte temporal se amplía**, lo que contribuye a **mitigar** los **riesgos** inherentes del mercado.

Capítulo 8: Implicaciones legales y éticas

En el presente proyecto, **definir diferentes factores legales y éticos** es importante para poder mostrar **transparencia** y mostrar el impacto del proyecto en las personas y las empresas. El reto, como se menciona al principio de este informe, está dirigido al **banco BBVA**, uno de los bancos más importantes y grandes a nivel mundial y nacional el cual dispone de suficientes recursos como para usar herramientas como la que se ha creado en este proyecto, que vienen siendo los modelos de predicción del 'payoff' de opciones o modelos de predicción de volatilidad, las cuales pequeños ahorradores o inversores no pueden llegar a adquirir o utilizar al no tener dichos recursos lo cual genera una **desigualdad** en el mercado pudiendo generar **desestabilidad** económica en algunos sectores.

Las fuentes utilizadas han sido **series temporales** de diferentes activos del índice bursátil de Dow Jones, donde se ha trabajado con una selección de tres activos que componen la cartera. Para poder trabajarlas de manera correcta se han acordado para que tengan las mismas fechas de inicio y final y el mismo espacio muestral, datos diarios, para que tengan la misma cantidad de datos. Los activos presentaban datos desde el '2020-06-02' hasta el '2021-07-01', datos de alrededor de un año y un mes. Estos datos **no llegan a ser del todo adecuados** debido a que pueden llegar a ser cortos, y lo más importante es que pertenecen a la época del **COVID**. Al pertenecer al año que ocurrió la pandemia, los datos pueden introducir **variabilidad no contemplada** o inesperada e introducir **sesgos**.

Unidos a posibles sesgos en resultados que se ha mencionado antes, ha habido algunas **limitaciones** a lo largo del proyecto como lo pueden ser en la parte de la predicción y **modelización de la volatilidad**. A la hora de realizar los modelos, se visualizó que los modelos no podrían realizar predicciones ya que en el caso de que las realizaran, podrían salir **predicciones sesgadas** debido a que ninguno de los modelos pasaba las pruebas necesarias para poder ser identificados como modelos con un buen ajuste y poder generar predicciones validas al **no captar patrones** de volatilidad.

Dejando de lado las limitaciones, a la hora de trabajar con **datos financieros**, se sabe que pueden llegar a variar o tener variaciones debido a **cambios impredecibles o incontrolables** que debido a la complejidad de los mercados financieros. Algunos de estos cambios pueden **cambios legislativos o políticos** que pueden hacer que valores de diferentes acciones cambien de una manera extrema, como la guerra de Ucrania y Rusia, demostrando que a la hora de realizar cualquier predicción también hay que tener en cuenta **factores externos** a parte de los datos cuantificables.

En el proyecto en concreto, se trata con opciones financieras, en concreto **opciones asiáticas**, las cuales pueden llegar a tener ciertos **riesgos** consigo. La modelización de este tipo de activos financieros puede llegar a **complicarse**, al mismo tiempo pudiendo acarrear malas predicciones y consecuentemente **perdidas de dinero** importantes para los inversores. Por lo tanto, a la hora de realizar las inversiones hay que tener en cuenta el riesgo que conlleva.

En resumidas cuentas, se hace referencia a los **ODS 10 y 16**, 'Reducción de las desigualdades' y 'Paz, justicia e instituciones sólidas' respectivamente. El ODS 10 a la hora de lograr la **igualdad del mercado** mencionada al principio y el ODS 16 de manera general al introducir **transparencia en la explicación de las limitaciones o factores éticos** para representarse como una institución sólida.

Capítulo 9: Bibliografía

- [1] A. A. Dar, M. S. Khan, I. Azad, A. K. Pathak, y G. Jayaraman, «Literature review: options and its applications», *SN Business & Economics*, vol. 4, n.o 8, jul. 2024, doi: 10.1007/s43546-024-00694-7.
- [2] N. Coelen, «Black-Scholes Option Pricing Model», 2002.
- [3] L. Fan y J. Sirignano, «MACHINE LEARNING METHODS FOR PRICING FINANCIAL DERIVATIVES», 2024.
- [4] C. Alberto Ruiz Marta Susana Basualdo Autor y D. Jorge Matich, «Cátedra: Informática Aplicada a la Ingeniería de Procesos-Orientación I Redes Neuronales: Conceptos Básicos y Aplicaciones».
- [5] A. Vélez Vélez *et al.*, «USO DE LA INTELIGENCIA ARTIFICIAL PARA LA OPTIMIZACIÓN DE LOS PROCESOS FINANCIEROS Y CONTABLES».
- [6] J. Briones Viqueira Tutor y X. Manuel Martínez Filgueira, «Creación de una red neuronal recurrente LSTM con machine learning».
- [7] J. Briones Viqueira Tutor y X. Manuel Martínez Filgueira, «Creación de una red neuronal recurrente LSTM con machine learning».
- [8] D. Martins, «Buy Apple Stock Now? 3 Important Metrics To Wat. TheStreet.», <https://www.thestreet.com/apple/stock/buy-apple-stock-now-3-important-metrics-to-watch>.
- [9] J. Mallinder, «Goldman Sachs and JPMorgan Investment Banking Profits Soar. Finance Monthly», <https://www.finance-monthly.com/2021/04/goldman-sachs-and-jpmorgan-investment-banking-profits-soar/>.

Apéndice I: Comparación resultados modelos testeados

Tabla 5: Métricas e hiper parámetros de modelos probados.

	Hidden size	Layers	Activation	Optimizer	MSE	MAE	R2
1	12	1	ReLU	Adam	0.00005	0.00588	0.99706
2	12	1	ReLU	SGD	0.03903	0.16078	-1.2889
3	12	1	LeakyReLU	Adam	0.00003	0.00448	0.99802
4	12	1	LeakyReLU	SGD	0.01464	0.09816	0.14105
5	12	1	Sigmoid	Adam	0.00001	0.00372	0.99889
6	12	1	Sigmoid	SGD	0.02915	0.13619	-0.7095
7	12	2	ReLU	Adam	0.00001	0.00247	0.99938
8	12	2	ReLU	SGD	0.01569	0.10111	0.07992
9	12	2	LeakyReLU	Adam	0.000007	0.00193	0.99580
10	12	2	LeakyReLU	SGD	0.01715	0.10622	-0.0060
11	12	2	Sigmoid	Adam	0.00003	0.00387	0.99889
12	12	2	Sigmoid	SGD	0.01915	0.13619	0.99819
13	12	3	ReLU	Adam	0.00004	0.00652	0.99710
14	12	3	ReLU	SGD	0.03698	0.15550	-1.0792
15	12	3	LeakyReLU	Adam	0.000009	0.00235	0.99943
16	12	3	LeakyReLU	SGD	0.14567	0.35817	-7.5416
17	12	3	Sigmoid	Adam	0.00001	0.00282	0.99907
18	12	3	Sigmoid	SGD	0.01705	0.10543	-0.0002
19	24	1	ReLU	Adam	0.00002	0.00441	0.99839
20	24	1	ReLU	SGD	0.01466	0.09569	0.14001
21	24	1	LeakyReLU	Adam	0.00001	0.00353	0.99887
22	24	1	LeakyReLU	SGD	0.02180	0.11743	-0.2786
23	24	1	Sigmoid	Adam	0.00004	0.00608	0.99726
24	24	1	Sigmoid	SGD	0.05921	0.20714	-2.4720
25	24	2	ReLU	Adam	0.00003	0.00530	0.99783
26	24	2	ReLU	SGD	0.02624	0.12970	-0.5388
27	24	2	LeakyReLU	Adam	0.000006	0.00203	0.99962
28	24	2	LeakyReLU	SGD	0.04256	0.16866	-1.4956
29	24	2	Sigmoid	Adam	0.00011	0.00994	0.99331
30	24	2	Sigmoid	SGD	0.01866	0.10893	-0.0944
31	24	3	ReLU	Adam	0.00001	0.00359	0.99898
32	24	3	ReLU	SGD	0.08901	0.26910	-4.2196
33	24	3	LeakyReLU	Adam	0.00002	0.00398	0.99882
34	24	3	LeakyReLU	SGD	0.02274	0.11926	-0.3335

35	24	3	Sigmoid	Adam	0.000005	0.00170	0.99968
36	24	3	Sigmoid	SGD	0.06721	0.22303	-2.9413

Apéndice II: Modelización de la volatilidad

A continuación, se muestran los diferentes resultados de los modelos ARCH(p), indicando como válido en p-valores si todos los valores de p son menores que 0.05, y en t-valores si todos los valores de 't' son mayores que 2, e inválido si todos los valores 'p' o 't' no cumplen el requisito. Cabe destacar que, para poder lograr un correcto modelo, los valores de 'p' y de 't' tienen que ser ambos válidos, es decir, tienen que cumplir el requisito arriba explicado. Se representan los resultados en la Tabla 6 y Tabla 7.

Tabla 6: Resultados ARCH Apple.

P	P-valores	T-valores
1	Válido	Inválido
2	Inválido	Inválido
3	Inválido	Inválido
4	Inválido	Inválido
5	Inválido	Inválido
6	Inválido	Inválido
7	Inválido	Inválido

Tabla 7: Resultados ARCH MRK.

P	P-valores	T-valores
1	Inválido	Inválido
2	Inválido	Inválido
3	Inválido	Inválido
4	Inválido	Inválido
5	Inválido	Inválido
6	Inválido	Inválido

Los gráficos de ACF y PACF indican que no sería recomendable realizar modelos GARCH, pero, aun así, se han creado para visualizar los resultados. A continuación, se muestran los resultados de los modelos GARCH (p,q) en la Tabla 8 y Tabla 9.

Tabla 8: Resultados GARCH AAPL.

p	q	P-valores	T-valores
1	5	Inválido	Inválido
1	6	Inválido	Inválido
1	7	Inválido	Inválido
2	5	Inválido	Inválido
2	6	Inválido	Inválido
2	7	Inválido	Inválido
3	5	Inválido	Inválido
3	6	Inválido	Inválido
3	7	Inválido	Inválido

4	5	Inválido	Inválido
4	6	Inválido	Inválido
4	7	Inválido	Inválido

Tabla 9: Resultados GARCH MRK.

p	q	P-valores	T-valores
2	7	Inválido	Inválido
2	8	Inválido	Inválido
2	9	Inválido	Inválido
3	7	Inválido	Inválido
3	8	Inválido	Inválido
3	9	Inválido	Inválido
4	7	Inválido	Inválido
4	8	Inválido	Inválido
4	9	Inválido	Inválido
5	7	Inválido	Inválido
5	8	Inválido	Inválido
5	9	Inválido	Inválido
6	7	Inválido	Inválido
6	8	Inválido	Inválido
6	9	Inválido	Inválido